


7. Clustering

Aprendizaje no supervisado



MD005 – Sistemas Basados en el Conocimiento

Manel Cerezo – manel.cerezo@salle.url.edu

Jordina Torrents – jordina.torrents@ext.salle.url.edu

David Larrosa – david.larrosa@salle.url.edu

Organización

2025

OCTUBRE						
L	M	X	J	V	S	D
		1	2	3	4	5
6	7	8	9	10	11	12
13	14	15	16	17	18	19
20	21	22	23	24	25	26
27	28	29				


NOVIEMBRE						
L	M	X	J	V	S	D
					1	2
3	4	5	6	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30

DICIEMBRE						
L	M	X	J	V	S	D
1	2	3	4	5	6	7
8	9	10	11	12	13	14
15	16	17	18	19	20	21
22	23	24	25	26	27	28
29	30	31				

2026

ENERO						
L	M	X	J	V	S	D
			1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	28	29	30	31	

FEBRERO						
L	M	X	J	V	S	D
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	



E1 - Clustering

A: 10 días (con dos fines de semana)

B: 12 días (con un fin de semana + sábado)

Organización



- ¿Qué es el Clustering/Agrupamiento?
- Modelos de Clustering
 - Tipos de métodos de agrupación
 - Agrupación jerárquica (+ código ejemplo)
 - K-means (+ código práctico)
 - DBSCAN (+ código práctico)
- Casos de uso de Clustering
- Presentación entrega Clustering

¿Qué es el Clustering/Agrupamiento?

¿Qué es el Clustering/Agrupamiento?

Consiste en dividir los datos disponibles en un número concreto de grupos determinados por la similitud entre estos. Se pretende:

- Maximizar la representabilidad de cada grupo
- Diferenciar entre 2 o más grupos



Tipos de modelos de agrupación (1)

Debemos elegir el método de agrupación dependiendo del problema.

- **Centroides:** los grupos se representan por un vector central (centroide). Cada punto se asigna al centroide más cercano.
- **Densidades:** los grupos se definen en base de la densidad de las muestras en el espacio de los datos.




Figure 1: Example of centroid-based clustering.




Figure 2: Example of density-based clustering.

Tipos de modelos de agrupación (2)

Debemos elegir el método de agrupación dependiendo del problema.

- **Distribuciones:** se asume un centro de cada clúster y se asocia una probabilidad de que cada muestra pertenezca a un grupo.
- **Conectividad:** el modelo se basa en la distancia entre sí de las muestras.




Figure 3: Example of distribution-based clustering.




Figure 4: Example of a hierarchical tree clustering animals.

Tipos de evaluación de los modelos de agrupación

Antes de entrar en como funcionan los modelos de agrupación, vamos a ver como que métodos de evaluación hay.

Internos: evalúan los clústeres mediante datos conseguidos por el modelo (distancia entre clústeres o capacidad intraclúster).

- Silhouette score
- Davies-Bouldin index
- Inercia (Clustering por centroides)

Externos: evalúan el Clustering comparándolo con una “verdad externa” (se usan labels para evaluar correctamente las evaluaciones hechas).

- Adjusted Rand Index (ARI)
- Normalized Mutual Information (NMI)
- F1

Evaluación de los modelos de agrupación internos

Antes de entrar en como funcionan los modelos de agrupación, vamos a ver como que métodos de evaluación genéricos hay.

- **Silhouette Score:** evalúa como un modelo ha sido capaz de diferenciar los clusters en función de la cercanía que tiene un dato con su cluster (a_i) en comparación al siguiente clúster más cercano (b_i).



$$\text{Silhouette Score} = \frac{b_i - a_i}{\max(a_i, b_i)}$$

- Si el punto está más cerca de su cluster que de otro cluster, el modelo ha separado bien los datos (Resultado ~ 1).
- Si el punto está entre medio de dos clusters, el modelo no está seguro, los clusters se sobreponen (Resultado ~ 0).
- Si el punto está más cerca de otro cluster que de su propio cluster, el modelo ha separado mal los datos (Resultado ~ -1).

Evaluación de los modelos de agrupación internos

Mejor usarlo con modelos que prioricen formas regulares (Silhouette alto) de lo contrario puede complicar la interpretación.

Silhouette analysis for KMeans clustering on sample data with n_clusters = 4



Evaluación de los modelos de agrupación internos

Antes de entrar en como funcionan los modelos de agrupación, vamos a ver como que métodos de evaluación genéricos hay.


- **Davies-Bouldin Index:** evalúa cómo de compactos son los clústeres (S_i y S_j) y como de separados entre ellos están (M_{ij}).

$$Davies\ Bouldin\ Index = \frac{1}{k} \sum_{i=1}^k \max \left(\frac{S_i + S_j}{M_{ij}} \right)$$

- Resultado ~ 0 : los clústeres están bien separados y son compactos (bueno).
- Cuanto mayor es el valor, peor es la calidad del Clustering, indicando clústeres con datos más dispersos y/o clústeres más cercanos entre sí (malo).

Evaluación de los modelos de agrupación internos

- **Inercia (para agrupamiento por centroides):** es la suma de las distancias de los elementos respecto a los centroides de cada grupo (internamente), por lo que el resultado será mejor cuantos más clústeres tengamos.



Evaluación de los modelos de agrupación externos

Antes de entrar en como funcionan los modelos de agrupación, vamos a ver como que métodos de evaluación genéricos hay.

- **Ajusted Rand Index (ARI):** evalúa la precisión del Clustering al comparar los resultados del Clustering en comparación con las clases reales teniendo en cuenta si la agrupación se ha hecho aleatoriamente o no.

$$Ajusted Rand Index = \frac{Rand Index - Expected(Rand Index)}{\max(Rand Index) - Expected(Rand Index)}$$

- El Clustering es prácticamente el mismo que las etiquetas reales (Resultado ~ 1).
- El modelo ha hecho las agrupaciones aleatoriamente (Resultado ~ 0).
- El Clustering es peor que hacer el agrupamiento aleatoriamente (Resultado < 0).

Evaluación de los modelos de agrupación externos

Antes de entrar en como funcionan los modelos de agrupación, vamos a ver como que métodos de evaluación genéricos hay.

- **Normalized Mutual Information (NMI):** evalúa la cantidad de información que comparten los datos basándose en la información mutua que comparten entre sí.

$$\text{Normalized Mutual Information}(Y, C) = \frac{2 * I(Y; C)}{H(Y) + H(C)}$$

Y = Clase real; C = Clúster predicho; I = Información mutua; H = entropía

- El Clustering es prácticamente el mismo que las etiquetas reales (Resultado ~ 1).
- Los datos no comparten información entre sí (Resultado ~ 0).

Clustering Jerárquico

Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.

Pseudocódigo:

1. Inicializar cada punto de datos como un clúster independiente.
2. Repetir hasta que todos los puntos estén fusionados en un único clúster:
 1. Calcular las distancias entre todos los clústeres.
 2. Fusionar los dos clústeres más cercanos según el criterio de enlace.
3. Opcional: cortar el dendograma en un nivel deseado para formar clústeres.
4. Retornar el árbol jerárquico o los clústeres seleccionados


Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.




Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.




Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.




Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.




Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.




Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.





Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.



Agrupación jerárquica

Ligeramente diferente a la mayoría de las aproximaciones, representa en forma de árbol (dendograma) la relación entre las muestras y los grupos de datos.



Agrupación jerárquica: Conclusiones

Funciona bien. Gracias al dendograma, el modelo tiene mucha explicabilidad, es intuitivo y visual.

¿Qué problema creéis que tiene el modelo?

Agrupación jerárquica: Conclusiones

Funciona realmente bien. Gracias al dendograma, el modelo tiene mucha explicabilidad, es intuitivo y visual.

¿Qué problema creéis que tiene el modelo?

- Coste excesivamente elevado.


$$\text{Coste} = O(n^3)$$

- En implementaciones más avanzadas.

$$\text{Coste} = O(n^2)$$

En datasets medianos/grandes el coste computacional puede ser muy elevado.

Agrupación jerárquica: Conclusiones



Ejemplo Clustering Jerárquico

K-means

K-means


Consiste en crear k clusters no superpuestos donde cada punto pertenece a un grupo donde el centroide (valor medio) es más cercano.

Pseudocódigo:

1. Inicializar k centroides aleatoriamente del conjunto de datos.
2. Repetir hasta convergencia:
 1. Asignar cada punto de datos al centroide más cercano
 2. Actualizar los centroides como la media de todos los puntos asignados a cada clúster.
3. Retornar los k clústeres y sus centroides.


K-means

- $K = 3$




K-means

- $K=3$




K-means

- $K=3$




K-means

- $K=3$



K-means

- $K = 3$





Evaluación K-means

- **Métodos internos**

- Inercia (grafico codo)
- Silhouette score (grafico coeficientes de Silhouette)
- Davies-Bouldin Index
- etc.

- **Métodos externos**

- Ajusted Rand Index
- Normalized Mutual Information (NMI)
- etc.



K-means: Conclusiones

¿Qué problema creéis que tiene el modelo?

K-means: Conclusiones

¿Qué problema creéis que tiene el modelo?

- Se necesita especificar el número de clusters (parámetro k).
- No es resistente a los outliers (moverá el centroide para añadirlos a un grupo)
- Muy costoso computacionalmente costoso:

$$\text{Coste} = O(n * k * d * i)$$

- n = numero de datos
 - k = numero de clústers
 - d = dimensionalidad de los datos
 - i = iteraciones necesarias para convergir
-
- En datasets medianos/grandes el coste computacional puede ser muy elevado.

Hand's on K-means

DBSCAN


DBSCAN

Density-Based Spatial Clustering of Applications with Noise. Agrupa los datos en clústers en función de su cercanía con otros grupos.

Pseudocódigo:


1. Inicializar escogiendo un punto al azar, con ϵ y MinPts definidos.
2. Para cada punto no visitado:
 1. Recuperar los puntos vecinos (dentro de ϵ)
 2. Si n° de vecinos $<$ MinPts, marcarlo como ruido.
 3. Si tiene al menos MinPts vecinos:
 1. Inicia un nuevo clúster.
 2. Expande el clúster añadiendo los puntos vecinos.
3. Retorna una lista de los clústeres formados y los puntos marcados como ruido. Repetir hasta que todos los puntos estén fusionados en un único clúster:

DBSCAN




DBSCAN

Definimos el parámetro *eps* (distancia entre nodos del mismo clúster) a 0.5




DBSCAN




DBSCAN

Definimos como *core point* lo puntos con $min_samples = 4$ (que mínimo tengan otros 4 puntos dentro de el área eps)




DBSCAN

Marcamos los puntos core




DBSCAN

Elegimos un punto core al azar, lo añadimos a un clúster, luego añadimos los puntos core de su alrededor (dentro de el área ϵ) al mismo clúster, miramos los datos cercanos, repetimos proceso...




DBSCAN




DBSCAN

Podemos ver que hay puntos que no son core, pero que forman parte de el área *eps* de un nodo core.




DBSCAN




DBSCAN


Cuando no se puede seguir, se buscan puntos core que aún no se hayan conectado.



DBSCAN




DBSCAN



Parametrización DBSCAN



- **MinPts:** Normalmente [1], para un dataset cuya dimensión > 2 , entonces $\text{MinPts} = 2 * \text{dimensión}$
 1. Para datasets pequeños, disminuir MinPts.
 2. Para datasets grandes o mucho ruido, incrementar MinPts.
 3. Ajustarlo al dominio del problema (número mínimo de clientes para segmentar el mercado...)
- Dado MinPts, entonces calcular **eps**:
 1. Calcular las distancias promedio a los k-vecinos más cercanos ($k=\text{MinPts}$).
 2. Ordenar las distancias de forma ascendente y graficarlas.
 3. Elegir eps en el punto de máxima curvatura de la gráfica (método del "codo").



Hand's on DBSCAN

Casos de uso de Clustering

¿Qué método utilizar?



Ejemplos

- Exploración de diagnósticos de pacientes
- Creación de equipo de fútbol en función de tipos de jugadores
- Agrupaciones de perfiles de clientes para ofertas marketing
- Tipos de artículos de noticias (NLP)
- Agrupación de sentimiento de palabras nuevas/"geosinónimos" (NLP)
- Tipos de imágenes (CV)
- Etc.

Presentación entrega Clustering

E1 - Clustering

- Cambio en método de corrección

Corrección

Bien

A mejorar


Mal

E1 - Clustering

Una empresa de helados llamada **La Vía Láctea** quiere hacer una campaña de marketing para aumentar la cantidad de clientes. Para hacer esto ha contactado a un equipo de investigación de la prestigiosa universidad de Harvard. Pero no estaban disponibles...

Así que decidieron ponerse en contacto con LaSalle para pedir el estudio de mercado a los estudiantes del MUDS.

El equipo de marketing de **La Vía Láctea** pide un estudio (en formato Jupyter notebook) que explique detalladamente los hallazgos encontrados durante el estudio y que plante una propuesta de estrategia para abordar una campaña exitosa.



E1 - Clustering

1. EDA (2.5p)
 1. Variables numéricas (1.25p)
 2. Variables categóricas (1.25p)
2. Procesado inicial de los datos (1.5p)
 1. Correlaciones (0.75p)
 2. PCA (0.75p)
3. Clustering (5p)
 1. Agrupación jerárquica (1 p)
 2. K-means (1 p)
 3. DBSCAN (1 p)
 4. Optics (Opcional +0,5 p. extras) -> El solamente se aplica si se tiene una nota superior a 5.
 5. Justificación decisiones (2 p)
4. Conclusión (1 p)

Entrega


A: 18 de enero

B: 24 de enero

⚠ Se tiene que justificar la toma de decisiones en cada uno de los puntos. ⚠

5. Clustering

Apredizaje no supervisado



MD005 – Sistemas Basados en el Conocimiento

Manel Cerezo – manel.cerezo@salle.url.edu

Jordina Torrents – jordina.torrents@ext.salle.url.edu

David Larrosa – david.larrosa@salle.url.edu