

Apuntes: Sistemas Basados en el Conocimiento

1. Introduccion: Tipos de Aprendizaje y Problemas

El objetivo principal es etiquetar datos de entrada (features) en categorias discretas (clases), a diferencia de la regresion que predice valores continuos.

Tipos de Aprendizaje:

- No Supervisado: No hay etiquetas (ground truth). Buscamos patrones.
- Supervisado: Entrenamos con datos que ya tienen la etiqueta correcta.

Tipos de Clasificacion:

- Binaria: Dos clases (0/1). Ej: Regresion Logistica.
- Multiclase: >2 grupos, cada dato pertenece a una sola clase. Ej: Arboles, KNN, SVM.
- Multilabel: Un dato puede pertenecer a varias clases a la vez (Ej. Segmentacion).

2. Regresion Logistica

Modelo base para clasificacion binaria. Se usa para clasificar, no para regresion.

Conceptos Clave:

- Funcion Sigmoide: Transforma valores a una probabilidad (0 a 1).

$$P(y=1|X) = 1 / (1 + e^{-z})$$

- Threshold (Umbral): Limite para decidir la clase.

- * Si $P > 0.5$ -> Clase 1

- * Si $P < 0.5$ -> Clase 0

Nota: En problemas desbalanceados, mover el threshold es vital.

- Funcion de Coste (Log Loss): Se minimiza iterativamente comparando con el ground truth.

Interpretacion de Coeficientes:

- B0 (Intercepto): Punto de partida.

- Bp (Coeficientes): Cuanto cambia la probabilidad al aumentar una unidad del predictor.

- (+) Aumenta prob. clase 1.

- (-) Disminuye prob. clase 1.

Pros: Interpretable, probabilistico, eficiente.

Contras: Malo si no hay separacion lineal.

3. Metricas y Estrategia: El caso del Cancer

Recall (Sensibilidad): De los casos reales positivos, cuantos detectamos?

$$\text{Recall} = TP / (TP + FN)$$

Importancia: En medicina, un Falso Negativo es fatal. Priorizamos Recall sobre Precision.

Apuntes: Sistemas Basados en el Conocimiento

Estrategias ante errores:

1. Analizar el Threshold: Bajarlo para capturar mas positivos (ej. > 0.3).
2. Data Augmentation: Crear datos sinteticos para equilibrar clases.

4. Maquina de Soporte Vectorial (SVM)

Busca el mejor limite de separacion (hiperplano).

Conceptos:

- Vectores de Soporte: Puntos mas cercanos al hiperplano. Son los unicos que definen el modelo.
- Margen: Distancia entre hiperplano y vectores de soporte (buscamos maximizarlo).

Hard Margin vs Soft Margin:

- Hard: Asume separacion perfecta (Overfitting).
- Soft: Permite cierto error para generalizar mejor (parametro C).

Kernel Trick:

Cuando los datos no son separables linealmente, proyecta los datos a una dimension superior.

Tipos: Lineal, Polinomico, RBF (Gaussiano, el mas usado), Sigmoidal.

5. Clasificacion Multiclase y No Lineal

A. Arboles de Decision:

- Divide el espacio basandose en pureza (Gini/Entropia).
- Problema: Overfitting. Solucion: Prunning (poda).

B. K-Nearest Neighbors (KNN):

- Clasifica un punto segun la mayoria de sus K vecinos mas cercanos.

Distancias:

- Euclidiana (Recta), Manhattan (Callejeando).
- Coseno: Mide el angulo. Vital en NLP y LLMs (Similitud semantica).

Pros y Contras KNN:

- (+) No asume distribucion.
- (-) Computacionalmente caro.
- (-) Sensible a outliers y dimension.