

MD005

Segundo entregable

Clasificación

15 / 19 de enero de 2026

1 Introducción

Este documento corresponde a la 2ª entrega de la asignatura MD005 (Sistemas Basados en el Conocimiento). El objetivo principal es aplicar algoritmos de clasificación a un dataset y analizar su desempeño.

1. **Motivaciones de compra en China:** Estudio sobre unos 400 consumidores en China (Kaggle: Fashion Shopping Motivations in China).
2. **Pokémon:** Información de 1025 pokémon a modo de pokédex (Kaggle: Data of 1010 Pokémons).
3. **NBA:** Datos de la NBA (National Basket Association) desde el 1996 hasta el 2021 con información de los jugadores (Kaggle: NBA Players Data).

2 Desarrollo

2.1 Procesado inicial

Análisis detallado de los datos del dataset seleccionado:

1. **Limpieza:** Verifica que los datos no contengan valores nulos o inconsistentes que puedan afectar al análisis.
2. **Clases:** Al tratarse de un problema de clasificación, identifica variables que permitan realizar tanto clasificación binaria como multiclase. ¿Existen variables en el dataset que cumplan con esta característica? Si es así, explícalas de forma detallada, utilizando técnicas aprendidas previamente (por ejemplo, en MD004). En caso contrario, justifica por qué consideras que no existen y proporciona ejemplos de variables que podrían ser útiles en el dataset seleccionado.
3. **Variables:** Aplica las transformaciones necesarias para adaptar las variables a los algoritmos que se van a emplear. Realiza un análisis de las variables importantes, justificando por qué lo son. Además, discute si las variables seleccionadas serán las mismas para todos los algoritmos, considerando las características particulares de cada uno.
4. **Conclusiones:** Expón las conclusiones derivadas del análisis y procesado inicial de los datos. ¿Qué conocimiento puedes extraer? ¿Es posible identificar las clases? ¿Podrían surgir problemas relacionados con la clasificación?

2.2 Clasificación

En esta sección se solicita la aplicación del mayor número posible de algoritmos de clasificación estudiados en clase (regresión logística, máquinas de soporte, árboles de decisión y KNN) para uno de los problemas seleccionados. Argumenta por qué los algoritmos elegidos son adecuados para el problema planteado y desarrolla la solución.

2.2.1 Algoritmos Según el problema, puede que no sea posible aplicar todos los algoritmos. En cualquier caso, se requiere que argumentes de forma razonada la parametrización de los modelos, interpretes los resultados obtenidos y evalúes de manera cualitativa el desempeño de cada algoritmo.

2.2.2 Optativo Como sección opcional, se solicita realizar una clasificación distinta a la resuelta en la sección principal (binaria/multiclase) empleando un único algoritmo de libre elección. Si no es posible, se permite generar una nueva variable que cumpla con la condición de clasificación. Esto puede lograrse eliminando la variable original y trabajando con la nueva, o bien combinando diferentes variables y añadiendo ruido para crear una nueva variable objetivo.

En caso de generar una nueva variable, el resultado obtenido será secundario; lo importante será el proceso seguido, ya que esta práctica tiene un enfoque educativo más que funcional.

3 Conclusiones

Presenta conclusiones globales de la entrega, incluyendo una comparativa de los modelos aplicados y las aproximaciones utilizadas. Argumenta cuál de los modelos resultó ser más efectivo y por qué.

4 Evaluación por sección

- **Procesado inicial:** 30%
- **Clasificación:** 45%
- **Conclusiones:** 25%
- **Optativa:** 0% + 10% adicional.

5 Dudas, preguntas

Cualquier duda o pregunta, enviadme un correo a (jordina.torrents@ext.salle.url.edu).

La fecha de entrega es el **25 / 29 de enero de 2026**.