


5. Regresión

Aprendizaje supervisado




MD005 – Sistemas Basados en el Conocimiento

Jordina Torrents - jordina.torrents@ext.salle.url.edu

¿Qué entendemos por regresión?


Métodos matemáticos que a partir de la **relación entre 2 variables** (lineal/no lineal) permiten **modelar** una de ellas en **función** de la otra dando lugar a 2 tipos de variables:

- **Dependientes:** Variable objetivo a predecir, **depende del resto** de variables para dar un valor.
- **Independientes:** Variable(s) utilizadas para modelar la variable dependiente, acompañadas de un coeficiente que define la importancia de cada una de ellas.



Agentes en una regresión

- **Variables dependientes e independientes:** Los modelos de regresión modelan la relación entre las variables dependientes (objetivo) e independientes (predictores).
- **Coeficientes de regresión:** Son los parámetros del modelo de regresión que se estiman a partir de los datos.
- **Línea/curva de regresión:** Función que mejor se ajusta a los puntos de datos.
- **Residuos:** Las diferencias entre los valores predichos y los valores reales.
- **Función de pérdida:** Mide el error del modelo. Por ejemplo, incluyen el error cuadrático medio (MSE) y el error absoluto medio (MAE).
- **Overfitting y Underfitting:** Los modelos de regresión deben equilibrar la complejidad y la simplicidad para generalizar bien en datos no vistos.
- **Técnicas de regularización:** Métodos como la regresión ridge y lasso se utilizan para evitar el sobreajuste al penalizar coeficientes grandes.



Objetivos de la regresión



1. Describir relaciones: Medir la influencia de una o más variables en otra variable
 - *¿Influye el nivel de educación de los padres en el rendimiento escolar de los alumnos?*
2. Hacer predicciones
 - *¿Qué película es más probable que vea según mi perfil?*
3. Explicar variabilidad
 - *¿Qué porcentaje de la variación en el nivel de felicidad de las personas se explica por su ingreso y horas de trabajo?*
4. Optimización y toma de decisiones
 - *¿Qué cantidad de recursos (personal, máquinas) se necesita en una planta de producción para minimizar los costos de producción sin afectar la calidad?*

Tipos de regresiones

Como habréis explorado en los datasets (y sabréis de antemano) hay relaciones que no van a ser lineales, aquí van unas cuantas:



- **Múltiple:** No hay una única variable independiente, tendremos n dimensiones (como nuestros datasets!)
- **Polinómica:** definida por un polinomio de grado n .
- **Cox:** utilizada en análisis de supervivencia.
- **Series temporales:** Información estructurada de forma que la posición es relevante i aporta información.

Tipos de regresiones



➡ Cox Regression

Regresión de supervivencia (Cox)



Métricas de error

- **Mean squared error (MSE):** Media del error cuadrático, focalizado en magnificar los errores grandes.
- **Mean absolute error (MAE):** Media del error absoluto, se utiliza para priorizar los errores pequeños al no elevar dicho error a potencias.
- **Root mean squared error (RMSE):** Raíz de MSE, muy utilizada al tener la medida en la misma unidad que los datos por lo tanto la podemos comparar de forma cualitativa y cuantitativa.
- **Mean absolute percentatge error (MAPE):** Error porcentual de la media, útil cuando queremos utilizar errores relativos.
- **R-squared (R^2):** Nos indica qué tan bien ajusta nuestra regresión a los datos dando como resultado 0 si no se ajusta nada y cercano a 1 cuando es prácticamente perfecta. Utilizada generalmente en conjunto a otras métricas de error (RMSE) para cuantificar el error.



Algoritmos


¿Dónde utilizamos las regresiones?

Situémonos en el caso del breast cancer y desde laboratorio nos indican que hay **algunas** muestras sobre las que no han sido capaces de medir 2 variables:

- Mean concave points
- Worst perimeter

Pero el analista nos comenta que sin dicha medida no puede hacer la segunda evaluación (nuestra regresión logística desarrollada la semana pasada) ...

¿Qué hacemos?



Algoritmos a utilizar



- **Regresión lineal/polinómica:** Regresión típica en forma de ecuación que se basa en minimizar el error para ajustar al máximo los puntos.
- **Árboles de regresión:** Al igual que los árboles de clasificación, aplica cortes que determinan el valor por sección (como una función a trozos) minimizando el error respecto a los puntos de entrenamiento.
- **Random Forest de regresión:** Combina múltiples árboles de regresión entrenados sobre diferentes muestras del conjunto de datos (mediante bootstrapping) y usando solo un subconjunto aleatorio de características en cada división (feature bagging).



Regresión Lineal y Polinómica

Regresión lineal/polinómica

- Asume que la **relación entre las variables es lineal** (ya sea positiva o negativa) y el error dependerá de la desviación de la muestra.



- Asume que la **relación** si bien no es lineal, **la modela una función** en la que los coeficientes dependen de una variable independiente junto con un error.


Regresión lineal/polinómica

- Habitualmente se usa el metodo de least squares para encontrar los coeficientes y el intercept de la función.
- Formula para regresión lineal simple:
 - Sum of Squared Errors (SSE): $\sum (y_i - (b + mx_i))^2$

InterceptCoefficient

Regresión lineal/polinómica

- Habitualmente se usa el metodo de least squares para encontrar los coeficientes y el intercept de la función.
- Formula para regresión lineal simple:
 - Sum of Squared Errors (SSE): $\sum (y_i - (b + mx_i))^2$



Resultado
predicción

Regresión lineal/polinómica

- Habitualmente se usa el metodo de **least squares** para encontrar los coeficientes y el intercept de la función.
- Formula para regresión lineal simple:
 - Sum of Squared Errors (SSE): $\sum (y_i - (b + mx_i))^2$
 - ...
 - Derivadas Parciales
 - ...
 - $m = (n * \sum xy - \sum x * \sum y) - (n * \sum x^2 - (\sum x)^2)$
 - $b = (\sum y - m * \sum x) / n$



Árboles de Regresión

Algoritmo de Aprendizaje

Para aprender un modelo de árbol de decisión, seguimos un enfoque *greedy*:

- Comenzamos con un árbol de decisión vacío (el espacio de características sin dividir).
- Elegimos el predictor 'óptimo' sobre el que realizar la partición y el umbral 'óptimo' aplicando un criterio de división (*splitting criterion*).
- Repetimos el proceso de forma recursiva en cada nuevo nodo hasta que se cumple una condición de parada (*stopping criterion*).

En clasificación, etiquetamos cada región del modelo con la clase a la que pertenece la mayoría de los puntos dentro de dicha región.

Adaptaciones para la Regresión

Con solo dos modificaciones, podemos usar un modelo de árbol de decisión para regresión:

1. Los tres criterios de división que hemos examinado promovían divisiones que eran puras: las nuevas regiones se especializaban cada vez más en una sola clase.
 - Para **clasificación**, la pureza de las regiones es un buen indicador del rendimiento del modelo.
 - Para **regresión**, queremos seleccionar un criterio de división que promueva divisiones que mejoren la precisión predictiva del modelo, medida, por ejemplo, por el MSE.
2. Para regresión con salida en $\mathbb{R}$, queremos etiquetar cada región del modelo con un número real, típicamente el promedio de los valores de salida de los puntos de entrenamiento contenidos en la región.

Árboles de Regresión: Entrenamiento

El algoritmo de aprendizaje para árboles de decisión en tareas de regresión es:

1. Comenzar con un árbol de decisión vacío (espacio de características no dividido).
2. Elegir un predictor j sobre el cual dividir y seleccionar un valor umbral t_j para la división, de manera que el **promedio ponderado del MSE** de las nuevas regiones sea lo más pequeño posible:

$$\operatorname{argmin}_{j,t_j} \left\{ \frac{N_1}{N} \operatorname{MSE}(R_1) + \frac{N_2}{N} \operatorname{MSE}(R_2) \right\}$$

o, de manera equivalente,

$$\operatorname{argmin}_{j,t_j} \left\{ \frac{N_1}{N} \operatorname{Var}(y|x \in R_1) + \frac{N_2}{N} \operatorname{Var}(y|x \in R_2) \right\}$$





donde N_i es el número de puntos de entrenamiento en R_i y N es el número total de puntos en R .

3. Repetir recursivamente en cada nuevo nodo hasta que se cumpla la condición de parada.


Árboles de Regresión: Predicción

Para cualquier punto de datos x_i :

1. Recorrer el árbol hasta llegar a un nodo hoja.
2. El valor promedio de la variable de respuesta y en la hoja (tomado del conjunto de entrenamiento) será la predicción $\hat{y}_i$.



.....



La escala de grises representa el MSE.

Condición de Parada: *Stopping Criterion*

En los árboles de decisión para regresión, necesitamos decidir cuándo detener la construcción del árbol para que no se vuelva demasiado complejo o aprenda demasiado los datos de entrenamiento.

Algunas condiciones de parada comunes son:

- **Profundidad máxima:** no permitir que el árbol siga creciendo más allá de cierto nivel.
- **Número mínimo de puntos en una región:** no dividir una región que tenga muy pocos datos.

En regresión, en lugar de usar la pureza (que sirve para clasificación), medimos la ganancia en precisión al hacer una división. Esto significa:


1. Comenzamos con todos los datos en una región R . Calculamos el MSE de esa región.
2. Probamos dividir la región usando un predictor x_j y un umbral t_j . Esto crea dos nuevas regiones: R_1 y R_2 .
3. Calculamos el MSE en cada subregión:
 1. $\text{MSE}(R_1)$ = error promedio de los puntos en R_1
 2. $\text{MSE}(R_2)$ = error promedio de los puntos en R_2
4. Calculamos el MSE ponderado de la división:

$$\text{MSE ponderado} = \frac{N_1}{N} \text{MSE}(R_1) + \frac{N_2}{N} \text{MSE}(R_2)$$

N_1 y N_2 = número de puntos en R_1 y R_2 , $N = N_1 + N_2$

5. Elegimos la división que minimice este MSE ponderado (mejor precisión).
6. Repetimos recursivamente en cada subregión hasta que se cumpla una condición de parada.

Sobreajuste (*Overfitting*)




Los mismos problemas que en los árboles de clasificación. Se debe evitar el sobreajuste (*overfitting*) mediante la poda (*pruning*) o limitando la profundidad del árbol y utilizando CV.

- **Pre-poda (Pre-pruning / Early stopping):** Detener el crecimiento del árbol antes de que sobreajuste, usando límites como profundidad máxima o mínimo número de muestras por nodo.
- **Post-poda (Post-pruning / Cost-complexity pruning):** Crear el árbol completo y luego eliminar ramas que no aportan mejora significativa en error, optimizando un criterio de complejidad-coste.
- **Poda de reducción de error (Error-based pruning):** Eliminar nodos si su eliminación no aumenta el error de predicción en un conjunto de validación.
- **Poda mínima de costo (Minimal cost-complexity pruning / α -pruning):** Introduce un parámetro α que penaliza la complejidad del árbol, eligiendo el árbol que minimiza $error + \alpha * \text{número de hojas}$.


RECAP - Clasificación multiclase: Árboles de clasificación

Temperature		Play Tennis
18	19	Yes
20	20.5	Yes
21	21.5	No
22	23	No
24	24.5	Yes
25		Yes
25	26.5	No
28	29	No
30	31	No
32		No



Árboles de regresión

Data		Target
18		0.1
20	19	0.6
21	20.5	0.5
22	21.5	0.3
24	23	0.2
25	24.5	1.2
25		1.5
28	26.5	5.6
30	29	2.3
32	31	6.6



Diferencias:

- La variable target es numerica continua
- **Substituimos Gini por R^2**
 - Unica la condición y variable raiz sera la que tenga menos valor R^2



iAl Código!

Polynomial Regression, Decision Trees



Random Forest Regressor

Bagging

Una forma de reducir la alta varianza en los resultados de un experimento es **repetir el experimento varias veces** y **luego promediar** los resultados obtenidos.


- **(Bootstrap)** Generamos múltiples muestras del conjunto de datos de entrenamiento mediante la técnica de *bootstrapping*, es decir, tomando muestras aleatorias con reemplazo del conjunto original. A continuación, **entrenamos un árbol de decisión completo** en cada una de estas muestras.
- **(Agregación)** Para realizar una predicción sobre una entrada nueva, **combinamos las predicciones de todos los modelos entrenados**. En el caso de **clasificación**, se **selecciona la clase que sea predicha por la mayoría de los modelos** (*votación por pluralidad*). En el caso de **regresión**, se **calcula el promedio de las salidas de todos los árboles** para obtener la predicción final.

Este procedimiento se conoce como **Bagging** (Breiman, 1996), abreviatura de *Bootstrap Aggregating*, que refleja su enfoque de generar múltiples muestras de entrenamiento (*bootstrap*) y luego combinar sus resultados (*aggregating*). Bagging es **especialmente útil para reducir la varianza de modelos inestables** como los árboles de decisión, **aumentando** así la **robustez** y **precisión** del modelo final.

Bagging

Cabe destacar que el **bagging** ofrece los siguientes beneficios:


- **Alta expresividad:** al utilizar árboles completos, cada modelo es capaz de aproximar funciones complejas y fronteras de decisión complicadas.
- **Baja varianza:** promediar las predicciones de todos los modelos reduce la varianza de la predicción final, siempre que se elija un número suficientemente grande de árboles.



Bagging

Pregunta: ¿Ves algún problema?


- Todavía puede haber **sobreajuste** si los árboles son demasiado grandes (*cross validation*).
- Si los árboles son demasiado poco profundos, puede **subajustar**.
- **Interpretabilidad:** El principal inconveniente del *bagging* (y de otros métodos de ensamblado) es que el modelo promediado **ya no es fácilmente interpretable**; es decir, ya no se puede seguir la “lógica” de una predicción a través de una serie de decisiones basadas en los valores de los predictores.



Caso de Subajuste (*Underfitting*)

Underfitting (subajuste) ocurre cuando un modelo es demasiado simple para capturar la estructura de los datos. En los árboles de regresión esto se traduce en:

- **Árboles poco profundos o con pocas divisiones:** Si el árbol no tiene suficiente profundidad, hace pocos cortes en los datos. Cada sección del árbol representa muchos puntos diferentes con un solo valor promedio.
- **Resultado:** el árbol no logra aproximar bien la función real que genera los datos; las predicciones están lejos de los valores reales en muchos casos.
- **Señal típica:** error de entrenamiento alto y también error de prueba alto, porque el modelo no “aprendió” la complejidad de los datos.



Out – Of – Bag (OOB) Error

El **Bagging** es un ejemplo de **método de ensamblado** (*ensemble method*), es decir, un método para construir un modelo único entrenando y agregando múltiples modelos.

Con los métodos de ensamblado obtenemos una nueva métrica para evaluar el desempeño predictivo del modelo: el **error fuera de la bolsa** (*out-of-bag error*).


Dado un conjunto de entrenamiento y un ensamblado de modelos, cada uno entrenado con una muestra *bootstrap*, calculamos el error fuera de la bolsa del modelo promedio de la siguiente manera:

- Para cada punto del conjunto de entrenamiento, se promedia la predicción de este punto **sobre los modelos cuyo conjunto de entrenamiento *bootstrap* no incluye este punto**.
- Luego, calculamos el error (o el error cuadrático) de esta predicción promedio. A esto se le llama **error fuera de la bolsa punto por punto** (*point-wise out-of-bag error*).
- Finalmente, se promedia este **error fuera de la bolsa punto por punto** sobre todo el conjunto de entrenamiento.

Out – Of – Bag (OOB) Error


Original Data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n



Bootstrap Sample 1

X	Y
X_4	y_4
X_{14}	y_{14}
X_1	y_1
X_2	y_2
X_{35}	y_{35}
$\vdots$	$\vdots$
X_k	y_k



Decision Tree 1




Used and unused data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n

Out – Of – Bag (OOB) Error


Original Data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n




Bootstrap Sample 2

X	Y
X_5	y_5
X_3	y_3
X_{12}	y_{12}
X_{43}	y_{43}
X_1	y_1
$\vdots$	$\vdots$
X_k	y_k



Decision Tree 2




Used and unused data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n

Out – Of – Bag (OOB) Error


Original Data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n




Bootstrap Sample 3

X	Y
X_9	y_9
X_4	y_4
X_1	y_1
X_1	y_1
X_{65}	y_{65}
$\vdots$	$\vdots$
X_k	y_k



Decision Tree 3




Used and unused data

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
X_4	y_4
X_5	y_5
$\vdots$	$\vdots$
X_n	y_n

Point-wise Out – Of – Bag (OOB) Error

B Trees that did not see $\{X_i, y_i\}$

X	Y
X_1	y_1
X_2	y_2
X_3	y_3
$\vdots$	$\vdots$
X_i	y_i
$\vdots$	$\vdots$
X_n	y_n



Classification

$$\hat{y}_{i,pw} = \text{majority}(\hat{y}_i)$$

$$e_i = \mathbb{I}(\hat{y}_{i,pw} = y_i)$$

Regression

$$\hat{y}_{i,pw} = \sum_{j \in B} \hat{y}_{i,j}$$

$$e_i = (y_i - \hat{y}_{i,pw})^2$$

OOB Error

Promediamos el **error** *out-of-bag* punto por punto sobre todo el conjunto de entrenamiento.

Classification



$$Error_{OOB} = \sum_i^n e_i = \sum_i^n \mathbb{I}(\hat{y}_{i,pw} \neq y_i)$$

Regression

$$Error_{OOB} = \sum_i^n e_i = \sum_i^n (y_i - \hat{y}_{i,pw})^2$$

Interpretabilidad

El **Bagging** mejora la precisión de las predicciones a costa de la interpretabilidad. Se calcula la **reducción total** que sufre el R^2 (para regresión) o el índice de Gini (para clasificación) debido a las divisiones realizadas sobre un predictor determinado, promediando este valor sobre los B árboles.



100 trees, max_depth=10

Interpretabilidad

El **Bagging** construye un conjunto de árboles entrenando cada uno sobre una **muestra bootstrap** del mismo conjunto de datos. La idea es que, al promediar sus predicciones, se reduzca la **varianza** del modelo. Sin embargo, **en la práctica muchos árboles terminan siendo muy parecidos entre sí**, es decir, **altamente correlacionados**. Esto pasa especialmente cuando hay predictores muy fuertes en los datos.

Supongamos que tenemos un conjunto de datos con varios predictores, y uno de ellos, x_j , es **mucho más informativo** que los demás para predecir la variable objetivo.

- Cada árbol, al construir su estructura con **greedy**, buscará **la mejor división en la primera capa**.
- Como x_j es el predictor más fuerte, **casi todos los árboles elegirán dividir primero con x_j** , aunque cada árbol vea una muestra *bootstrap* distinta.

Esto significa que, aunque Bagging genera muchos árboles diferentes, **algunos patrones dominantes en los datos hacen que los árboles sean muy similares**:

- Cada árbol tiene una distribución muy parecida (lo llamamos “**distribución idéntica**”).
- La **predicción promedio del conjunto** no reduce la varianza tanto como se espera, porque todos los árboles tienden a hacer predicciones parecidas.

Random Forest de Regresión

Random Forest es una forma modificada de *Bagging* que crea conjuntos (*ensembles*) de árboles de decisión independientes.

Para **descorrelacionar** los árboles, hacemos lo siguiente:

- **Entrenamos cada árbol con una muestra *bootstrap* diferente** del conjunto de entrenamiento completo (igual que en Bagging).
- Para cada árbol, en cada división, **seleccionamos aleatoriamente un subconjunto de J' predictores** del conjunto completo de predictores.
- Entre estos J' predictores, **elegimos el predictor óptimo y el umbral correspondiente óptimo** para realizar la división.

Los modelos de **Random Forest** tienen múltiples **hiperparámetros** que se pueden ajustar:

- El **número de predictores** a seleccionar aleatoriamente en cada división.
- El **número total de árboles** en el conjunto (*ensemble*).
- El **tamaño mínimo de los nodos hoja**.

En teoría, cada árbol del Random Forest es completo, pero en la práctica esto puede ser **computacionalmente costoso** (y generar redundancias en el modelo). Por ello, **no es raro imponer un tamaño mínimo de nodo**.


Random Forest de Regresión

Existen **valores estándar (por defecto)** para cada uno de los hiperparámetros de Random Forest, recomendados por practicantes con experiencia, pero en general estos parámetros deben **ajustarse mediante el error fuera de la bolsa (OOB)**, haciéndolos dependientes de los datos y del problema específico.

Por ejemplo, el **número de predictors (*features*) a seleccionar aleatoriamente en cada división**:

- $\sqrt{N_j}$ para clasificación
- $N/3$ para regresión

Usando los **errores fuera de la bolsa**, el entrenamiento y la validación cruzada pueden realizarse en **una sola secuencia**; se deja de entrenar una vez que el error fuera de la bolsa se estabiliza.



Importancia Variables en Random Forest de Regresión

Igual que con Bagging:

Se calcula la **reducción total** que sufre el R^2 (para regresión) o el índice de Gini (para clasificación) debido a las divisiones realizadas sobre un predictor determinado, **promediando este valor sobre los B árboles**.

Alternativa:

- Se registra la **precisión de predicción** en las muestras fuera de la bolsa (*out-of-bag*, OOB) para cada árbol.
- Se **permute aleatoriamente** la columna j en las muestras OOB y se vuelve a registrar la precisión.
- La **disminución en la precisión** como resultado de esta permutación se **promedia sobre todos los árboles**, y se utiliza como una **medida de la importancia de la variable j** en el Random Forest.

Importancia Variables en Random Forest de Regresión

Cuando el número de predictores es grande, pero el número de predictores relevantes es pequeño, los **Random Forest** pueden tener un rendimiento bajo.

Pregunta: ¿Por qué?

En cada división, la **probabilidad de seleccionar un predictor relevante es baja**, por lo que la mayoría de los árboles del conjunto serán **modelos débiles**.

Aumentar el **número de árboles** en el conjunto generalmente **no incrementa el riesgo de sobreajuste**. Nuevamente, al descomponer el error de generalización en términos de **sesgo (bias) y varianza (variance)**, vemos que aumentar el número de árboles produce un modelo que es **al menos tan robusto como un solo árbol**.

Sin embargo, si el número de árboles es **demasiado grande**, los árboles en el conjunto pueden volverse **más correlacionados**, lo que puede **aumentar la varianza**.



iAl Código!

Polynomial Regression, SVC, Random Forest
Regressor



Inciso en series temporales

Qué són y para qué sirven las series temporales

Las series temporales tienen una categoría 'especial' dentro de las regresiones porque la posición nos aporta información relevante a diferencia del resto de problemas de regresión.


Nos permiten encontrar patrones y tendencias a partir de analizar los datos para:

- **Predicción:** Predecir el 'futuro' de la variable a partir de los anteriores por lo que asumirá que el sistema es estanco y cíclico. Hay sectores en los que es más factible que suceda como por ejemplo, la contaminación en las ciudades pero en otros como la bolsa de valores o comportamientos humanos es mucho más complicado.
- **Análisis de tendencias:** Podemos analizar la tendencia a diferentes niveles de granularidad para planificar y no necesariamente para predecir el valor de las ventas. Identificar patrones temporales cae dentro del análisis.
- **Detección de anomalías:** Descubrir patrones inesperados dentro del funcionamiento 'homogéneo' del sistema, como por ejemplo, en ciertas zonas, descubrir el uso fraudulento de la conexión a la red eléctrica, fraude fiscal o identificar casos de arritmia cardíaca.

Características en series temporales

Se buscan 3 características principales para saber si podremos trabajar la serie temporal o si necesitaremos realizar un procesamiento extremo para su análisis:

- **Estacionalidad:** Media y desviación constantes en el tiempo.
- **Temporalidad:** Si hay fluctuaciones periódicas.
- **Autocorrelación:** Si tenemos un valor que tenga una alta correlación con el comportamiento posterior.



Algoritmos

Tipo de modelo	Algoritmo / Método	Descripción breve
Modelos estadísticos clásicos	AR (Autoregresivo)	Predice el valor futuro usando valores pasados de la serie.
	MA (Media Móvil)	Predice usando promedios de errores pasados.
	ARMA (Autoregresivo + Media Móvil)	Combina AR y MA; útil para series estacionarias.
	ARIMA (Autoregresivo Integrado de Media Móvil)	Maneja series no estacionarias mediante diferenciación.
	SARIMA (ARIMA estacional)	Extiende ARIMA considerando patrones estacionales.
	Suavizamiento Exponencial	Da más peso a los datos recientes; variantes: simple, Holt (tendencia), Holt-Winters (tendencia + estacionalidad).
	Regresión lineal o polinómica con retardos	Usa valores pasados como variables predictoras.
Aprendizaje automático	k-Nearest Neighbors (kNN)	Predice usando patrones pasados similares.
	Random Forest / Gradient Boosting	Usa retardos de la serie como features; maneja no linealidades.
	Support Vector Regression (SVR)	Para series no lineales y con ruido.
Redes neuronales	MLP (Multilayer Perceptron)	Usando retardos de la serie como entradas.
	RNN (Redes Neuronales Recurrentes)	Captura dependencias temporales a corto plazo.
	LSTM (Long Short-Term Memory)	Maneja secuencias largas y evita desvanecimiento de gradiente.
	GRU (Gated Recurrent Units)	Variante más simple y eficiente que LSTM.
	Transformers para series temporales	Usa atención para capturar dependencias a largo plazo; muy potente para series complejas.

5. Regresión

Aprendizaje supervisado



MD005 – Sistemas Basados en el Conocimiento

Jordina Torrents - jordina.torrents@ext.salle.url.edu

Detail of a manuscript page showing a large, ornate initial 'C' and the text 'Carnation'.