

MD005

Tercer entregable

Regression

22 / 26 de enero de 2026

1 Introducción

Este documento corresponde a la 3ª entrega de la asignatura MD005 (Sistemas Basados en el Conocimiento). El objetivo principal es aplicar algoritmos de regresión a un dataset y analizar su desempeño.

1. **Motivaciones de compra en China:** Estudio sobre unos 400 consumidores en China (Kaggle: Fashion Shopping Motivations in China).
2. **Pokémon:** Información de 1025 pokémon a modo de pokédex (Kaggle: Data of 1010 Pokémons).
3. **NBA:** Datos de la NBA (National Basket Association) desde el 1996 hasta el 2021 con información de los jugadores (Kaggle: NBA Players Data).

2 Desarrollo

2.1 Procesado inicial

Análisis detallado de los datos del dataset seleccionado. Aunque el dataset sea el mismo que en las entregas anteriores, el enfoque del problema es completamente distinto, por lo que el análisis también debe serlo.

1. **Limpieza:** Comprobad que los datos no tienen valores nulos o valores que no pintan nada en los datos.
2. **Variables:** Analiza y explora las variables. ¿Hay correlación entre ellas? ¿Qué variable utilizarías como variable dependiente? ¿Y cuál como variable independiente? Quizá se pueden utilizar varias y mejorar los resultados que si solamente tenemos en cuenta una de ellas.
3. **Conclusiones:** Conclusiones sobre el análisis y procesado inicial de los datos, así como la selección de variables para realizar la regresión.

Como parte final del procesado, eliminad algunos valores de la variable objetivo (entre el 5-10% de las muestras). Con este proceso final, tendremos ciertas muestras sin registros que quizá no tiene sentido en primera instancia, añade sentido en la parte optativa.

2.2 Regresión

Escoged 2 algoritmos para realizar la regresión (e.g., regresión lineal o polinómica, árboles de regresión, random forest de regresión) y aplicadlos sobre las variables seleccionadas, justificando los motivos de elección y describiendo la parametrización necesaria. Comparad qué tan bien se ajustan los modelos,

analizad los resultados obtenidos y cualquier otro aspecto que consideréis relevante. Finalmente, seleccionad un modelo ganador, ya sea por proporcionar el error mínimo, ser el más rápido o una combinación de ambos criterios.

2.2.2 Optativo Como en todas las entregas, ¡tenemos una sección optativa! En este caso, se mezclará la entrega anterior con la actual. Queremos realizar una clasificación, pero hay muestras que no tienen registros (por eso las hemos eliminado previamente). Utilizad un algoritmo de clasificación (el que prefiráis) con el conjunto de datos sin las muestras eliminadas y comprobad que la matriz de confusión tiene sentido. Rellenad las variables faltantes utilizando vuestra regresión y entrenad el mismo algoritmo bajo las mismas condiciones (aunque ahora el conjunto de datos tendrá unas pocas muestras adicionales). Finalmente, realizad la clasificación con el conjunto de datos inicial (sin eliminar las muestras) y comparad los tres resultados. ¿Cuál ofrece mejores resultados? ¿Mejora el desempeño al utilizar datos ‘sintéticos’ generados mediante la regresión? ¿Qué tan bien se ha comportado el algoritmo en cada caso?

3 Conclusiones

Conclusiones finales de la entrega, principalmente sobre la selección de variables, qué tan correlacionadas están y qué tan bien se ajusta el mejor modelo de regresión a los datos disponibles. En caso de realizar la sección optativa, desarrollad también las conclusiones al respecto.

4 Evaluación por sección

- **Procesado inicial:** 30%
- **Clasificación:** 45%
- **Conclusiones:** 25%
- **Optativa:** 0% + 10% adicional.

5 Dudas, preguntas

Cualquier duda o pregunta, enviad un correo a jordina.torrents@ext.salle.url.edu.

La fecha de entrega es el **1 / 5 de febrero de 2026**.